

저비용 탁구연습 보조시스템*

임세민⁰¹ 김건우¹ 양종운¹ 박주영² 오형철²¹고려대학교 대학원 전자정보공학과²고려대학교 과학기술대학

{jaewoong819, asdv1234, yju3301, parkj, ohyeong}@korea.ac.kr

Low Cost Assistive System for Table Tennis Practice

Se-Min Lim⁰¹ Keon-Woo Kim¹ Jong-Wun Yang¹ Jooyoung Park² Hyeong-Cheol Oh²¹Dept of Electronic and Information Eng., Graduate School, Korea University²College of Science and Tech., Korea University

요 약

본 논문에서는 탁구연습에 사용될 저렴한 휴대용 장치를 위한 효율적인 추론 회로를 모색하였다. 요즘 동작 인식 문제에서 딥 러닝 기술이 가장 좋은 해결 방안으로 보편적으로 인식되고 있지만, 딥 러닝 기술의 구현 비용은 종종 소규모 응용에서는 감당하기 어려운 부담이 된다. 본 논문은 딥 러닝 기술의 대안이 될 수 있는 여러 가지 방안들을 평가하여, 코사인 유사도를 사용하는 기술이 좋은 대안이 될 수 있음을 보였다.

1. 서 론

최근 스마트 보조기술 분야에서, 사람의 움직임에 관한 정보를 분석하여 행동을 인식하는 기술의 적용이 활발하게 연구되고 있다[1,2]. 관련 연구의 일환으로서, 손과 팔에 부착된 3개의 센서 모듈에서 수신되는 정보로부터 사용자가 취한 동작이 탁구의 기본동작 중 어느 동작에 해당하는가를 추론(Inference)하여 사용자에게 알려주는 시스템이 제안된 바 있다[2].

논문[2]의 시스템은 딥 러닝 기술을 사용하였는데, 휴대용 기기에서의 적용에 비용 또는 성능 면에서 어려움이 있다. 본 논문에서는 딥러닝 기술 대신, 특징점 사이의 유사도를 평가하는데 흔히 사용되는 기술들을 적용하여, 사용자가 취한 동작을 추론하는 휴대용 단말기를 보다 저렴하게 구성하는 방안을 모색하였다.

2. 유사도 평가 기법

유사도를 평가하는 기법에서는, N 차원의 탐색공간 S 내에서 주어진 특징점 k^G 와, 특정의 거리척도(Distance Measure) $dist(k, k^G)$ 를 기준으로, 가장 가까운 특징점

k , 즉 $\argmin_{k \in S} dist(k, k^G)$ 을 찾는다. 거리척도로는 식(1)과 같이 정의되는 L_1 norm (또는 SAD; Sum of Absolute Difference) 또는 L_2 norm (또는 SSD; Sum of Squared Difference)이 흔히 사용된다.

$$L_m(k, k^G) = \left(\sum_{i=1}^N |k_i - k_i^G|^m \right)^{\frac{1}{m}} \quad (1)$$

또한 식(2)와 같이 정의되는 코사인 유사도(Cosine Similarity)도 많이 사용된다.

$$cos_sim(k, k^G) = \frac{k \cdot k^G}{\|k\| \|k^G\|} \quad (2)$$

본 논문에서는 L_1 norm과 L_2 norm 및 코사인 유사도를 사용하는 평가 기법들을 고려하였다.

2.1 데이터 수집

본 논문에서는, 논문[2]에서와 같이 라즈베리파이 보드에 접속된 3개의 IMU센서를 손과 팔에 부착하여 수집한 데이터를 사용하였다. 숙련도가 다른 운동자 5인으로부터 각각 5개 타법의 동작에 대한 데이터를 수집하여 유사도 평가 기법들을 비교하였다.

* 본 논문은 한국연구재단 중견과제(과제번호: 2017R1E1A1A03070652)의 지원으로 수행되었습니다.

2.2 정확도

Intel i7-4790K CPU를 사용하는 컴퓨터에서, 테스트 용으로 선택된 30%의 데이터와 각 타법에 속하는 나머지 데이터와의 유사도를 계산하여 가장 유사도가 높은 동작으로 추론하였다.

그림 1은 추론 정확도 계산 알고리즘을 보인 것이다. 센서 3개 각각의 x, y, z 방향 가속도 및 자이로 데이터 (총 feature 개수 = 18)들을, 한 동작을 표현하는 27개 시간점(time series 길이 = 27)에서 수집하여, 크기가 18x27인 윈도우들로 구성하고, 학습 데이터의 윈도우와 테스트 데이터의 윈도우를 비교하여 가장 높은 유사도 값을 가지는 특정 사람의 특정타법을 결과로 출력하게 하여 정확도를 계산하였다.

```

For i in 5 people's 5 postures(25)
  For x in total features(18)
    For y in time series(27)
      similarity[x] = calculate_similarity(test[x,y],train[x,y])
      temp_result[i] = max(similarity[x])
result = max(temp_result[i])
    
```

그림 1. 추론 정확도 계산 알고리즘

표 1은 숙련도가 비교적 높은 운동자(Player 1)의 데이터에 대하여 추론한 결과의 정확도를 LSTM(Long Short-Term Memory) 순환신경망(Recurrent Neural Network; RNN)을 사용한 논문[2]를 응용하여 특정 사람의 특정 타법을 추론한 정확도와 비교한 것이다. 딥 러닝 기술에 비하여는 정확도가 부족하지만, 유사도 기술 간에는 현저한 차이가 관찰되지 않았다.

	정확도
코사인 유사도	80
L_1 norm 유사도	73
L_2 norm 유사도	73
LSTM RNN	93

표 1. 기술 별 정확도 (%)

표 2는 유사도 평가기술들을 운동자 별로 비교한 결과이다. L_1 및 L_2 norm은 운동자의 숙련도에 따라 정확도의 차이가 현저해지는 반면, 코사인 유사도는 비교적 안

정된 정확도를 보임을 알 수 있어, 본 논문에서는 코사인 유사도를 이용하는 방안에 관심을 두었다.

	코사인 유사도	L_1 norm 유사도	L_2 norm 유사도
Player 1	80	73	73
Player 2	80	67	73
Player 3	73	60	53
Player 4	73	47	53
Player 5	73	47	40

표 2. 운동자에 따른 정확도 (%)

3. 구 현

3.1 설계

그림 2은 설계한 가속기의 블록도를 보인 것이다. 메모리에서 연속적으로 입력되는 데이터로부터 블록도의 계산을 거쳐 최종적으로 유사도 값을 얻어낸다. 한 동작을 표현하는 데이터가 27개이므로, 부호가 있는 27개의 정수 쌍을 곱하거나 제곱을 구한 후 축적하였다. 축적된 결과는 단정밀도 부동 소수점 표현으로 변환되고 곱셈과 제곱근 연산 및 나눗셈 연산이 수행되도록 구성하였다. 설계된 가속기는 매 27개 클럭 사이클(clock cycle)마다 새로운 동작 데이터와 비교를 시작하는 파이프라인 구조이다.

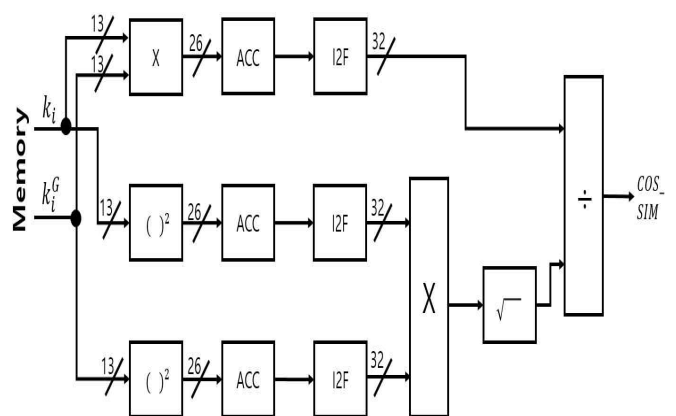


그림 2. 가속기의 블록도

3.2 평가

설계된 코사인 유사도 기반의 하드웨어 가속기는 베릴

로그 언어로 모델화하였고, Quartus Prime 17.0을 사용하여, DE1-SoC 보드[3]에서 사용하는 FPGA인 Intel사의 5CSEMA5F31C6를 타겟으로 합성하였다.

	동작주파수 [MHz]	수행시간 [s]
그림 1 (코사인 유사도)	174	0.49×10^{-3}
Cortex-A9/DE1-SoC (LSTM RNN)	25	100.17
i7-4790K/Desktop (LSTM RNN)	4001	0.03×10^{-3}

표 3. 동작성능의 비교

표 3의 첫 번째 행은 합성된 가속기의 최대동작주파수와 이 주파수로 수집된 한 동작의 데이터를, 메모리에서 계속 입력되는 3150개 동작의 데이터와 유사도를 비교하는데 소요되는 시간을 보인 것이다. 두 번째 행은 DE1-SoC 보드의 메모리에 저장되어있는 논문[2]의 가지치기(pruning) 전의 LSTM RNN 모델을 사용하여, 수집된 한 동작의 데이터가 어느 운동자의 어느 타법에 가장 유사한가를 DE1-SoC의 ARM-Cortex A9 컴퓨터로 계산한 결과이고, 마지막 행은 i7-4790K를 장착한 데스크탑 컴퓨터에서 가지치기(pruning)가 된 모델을 사용하여 같은 계산을 수행한 결과이다. 설계된 가속기의 경우에만 메모리 접근 속도 등의 오버헤드가 무시된 평가이지만, ARM 코어만을 사용하여 딥러닝 기반으로 구현한 가속기는 고려된 간단한 작업에도 지나치게 오랜 시간을 소요하는 데 비하여, 설계한 가속기는 메모리 접근 속도를 25MHz로 낮추어도 약 3.4msec에 고려된 작업을 수행할 수 있으므로, 보다 복잡한 형태의 작업도 실시간으로 수행할 수 있다는 가능성을 보여준다.

	ALMs	FFs	DSPs
그림 1	1544	2577	8

표 4. 설계된 가속기의 리소스 사용[개]

표 4는 설계된 코사인 유사도 기반 하드웨어 가속기를 FPGA상에 구현할 때 필요한 리소스를 나타낸다. 개발 중인 코사인 유사도 기반 방법론은 LSTM 기반 방법론보다 정확도가 아직 약 13%정도 낮지만, 일반적인 딥 러

닝 기반 하드웨어 가속기(예를 들면 [4,5])에 비해 현저히 적은 비용으로 구현할 수 있다.

IV. 결론 및 향후 연구 방향

본 논문의 코사인 유사도 기반 하드웨어 가속기는 기존의 LSTM 기반 가속기들에 비하여 정확도는 낮으나, 현저히 저렴한 비용으로 구현할 수 있어, 저가의 소형 휴대용 장비에의 응용에 유용하게 사용될 수 있을 것으로 기대된다.

낮은 정확도를 개선하기 위하여, SVM(Support Vector Machine)이나 ELM(Extreme Learning Machine) 등 LSTM에 비해 신경망 크기가 작고 빠른 학습이 가능한 기계학습 방법론의 적용이나 측정 데이터를 구간 별로 비교하는 방안[6] 등의 적용을 고려하고 있다. 또한 보다 정확한 비교를 위하여, 논문[2]의 LSTM 기반 하드웨어 가속기도 개발 중이다.

참고문헌

- [1] M. Kranz, et al., The Mobile fitness coach: Towards individualized skill assessment using personalized mobile devices. Pervasive and Mobile Computing. 9(2), pp.203-215, 2013.
- [2] 임세민 외, “딥 러닝을 이용한 탁구연습 보조시스템”, 한국정보과학회 KSC 2017 논문집, pp.960-- 962, 2017년 12월.
- [3] <http://www.terasic.com.tw/cgi-bin/page/archive.pl?Language=English&No=836>
- [4] Y. Guan, et al., “FPGA-based accelerator for long short-term memory recurrent neural networks”, Design Automation Conference (ASP-DAC), 2017 22nd Asia and South Pacific, February 2017.
- [5] Y. Zhang, et al., “A Power-efficient accelerator based on FPGAs for LSTM network”, Cluster Computing (CLUSTER), 2017 IEEE International Conference on, September 2017.
- [6] Y. Zhu, et al., “Human activity recognition based on similarity”, Computational Science and Engineering (CSE), 2014 IEEE 17th International Conference on, January 2015.